

PÓS-GRADUAÇÃO EM CIÊNCIA DE DADOS
Centro Universitário de Brasília — CEUB

GUIA PRÁTICO DE
ANÁLISE DE DADOS E MACHINE
LEARNING
COM PYTHON E CRISP-DM

Apostila de Consulta — Scripts Genéricos e Referência Rápida
Introdução em Aprendizagem de Máquina · Aulas 1 e 2

Este material serve como guia de consulta permanente, aplicável a qualquer dataset.
Todos os scripts são genéricos e acompanhados de comentários explicativos.

O QUE É O CRISP-DM E POR QUE USÁ-LO?

O CRISP-DM (Cross-Industry Standard Process for Data Mining) é a metodologia mais utilizada em projetos de Ciência de Dados — adotada em mais de 70% dos projetos ao redor do mundo. Ele divide o trabalho em 6 fases iterativas e bem definidas, garantindo que o trabalho seja organizado, reproduzível e alinhado ao objetivo de negócio.

Fase	Nome	Objetivo Principal
1	Entendimento do Negócio	Definir o problema e os critérios de sucesso
2	Entendimento dos Dados	Explorar e conhecer os dados disponíveis (EDA)
3	Preparação dos Dados	Limpar, tratar e transformar os dados
4	Modelagem	Treinar e ajustar algoritmos de Machine Learning
5	Avaliação	Medir o desempenho real do modelo (RMSE, R^2 , MAE)
6	Implantação	Colocar o modelo em produção e monitorar



O processo é cíclico!

As fases não são lineares. É comum voltar à fase anterior ao descobrir algo novo.

Exemplo: durante a Modelagem (fase 4), você percebe que precisa criar uma nova variável → volta para Preparação (fase 3).

FASE 0 — CONFIGURAÇÃO DO AMBIENTE

Antes de iniciar qualquer projeto, execute a célula de configuração abaixo. Ela importa todas as bibliotecas necessárias e define padrões visuais.

0.1 — Importações e Configurações Globais

```
# — IMPORTAÇÕES ESSENCIAIS —————
# pandas: manipulação de tabelas (DataFrames)
import pandas as pd

# numpy: cálculos matemáticos e arrays
import numpy as np

# matplotlib: criação de gráficos (biblioteca base)
import matplotlib.pyplot as plt

# seaborn: gráficos estatísticos com visual aprimorado
import seaborn as sns

# scikit-learn: algoritmos de Machine Learning
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score, mean_absolute_error

# pickle: salvar e carregar modelos treinados
import pickle

# — CONFIGURAÇÕES VISUAIS —————
# permite ver gráficos diretamente no Jupyter/Colab
%matplotlib inline

# tamanho padrão dos gráficos (largura x altura em polegadas)
plt.rcParams['figure.figsize'] = (12, 5)

# tema visual do seaborn (opções: whitegrid, darkgrid, white, dark)
sns.set_theme(style='whitegrid')

# formatar números com 2 casas decimais nas tabelas
pd.set_option('display.float_format', '{:.2f}'.format)

# — VERIFICAÇÃO —————
print(f"Pandas:      {pd.__version__}")
print(f"NumPy:        {np.__version__}")
print(f"Seaborn:       {sns.__version__}")
print('Ambiente configurado com sucesso!')
```

✓ Por que importar tudo de uma vez?

Centralizar as importações no início facilita a leitura e evita erros de "módulo não encontrado" no meio da análise.

`random_state=42` é uma convenção: garante que resultados aleatórios sejam reproduzíveis entre execuções.

1

ENTENDIMENTO DO NEGÓCIO

Definir o problema antes de abrir qualquer dado

A primeira fase é conceitual, não envolve código. Seu objetivo é responder com clareza: o que queremos prever ou descobrir? Sem essa definição, qualquer solução estará errada.

1.1 — Perguntas para Definir o Problema

Pergunta	Exemplo Prático
Qual é o objetivo de negócio?	Prever o preço de imóveis em Brasília
O que será previsto (target)?	Coluna preco_mil (valor em R\$ milhares)
Qual o tipo de problema?	REGRESSÃO — prevemos um número contínuo
O que define sucesso?	Erro médio menor que R\$ 100 mil (RMSE < 100)
Quais dados temos disponíveis?	Área, tipo, bairro, quartos, vagas, ano
Há restrições ou limitações?	Outliers de imóveis de luxo acima de R\$ 5M

1.2 — Regressão ou Classificação?

A natureza da variável-alvo (target) define o tipo de algoritmo:

A resposta é...	Tipo de Problema	Exemplos de Algoritmo	Métrica Principal
Um NÚMERO contínuo	REGRESSÃO	LinearRegression, RandomForest	RMSE, MAE, R ²
Uma CATEGORIA / CLASSE	CLASSIFICAÇÃO	LogisticRegression, SVM	Acurácia, F1-Score

⚠ Checklist da Fase 1

- ☐ O problema está claramente definido em uma frase
- ☐ A variável-alvo (target) foi identificada
- ☐ O tipo de problema foi definido (regressão ou classificação)
- ☐ Os critérios de sucesso foram estabelecidos

2

ENTENDIMENTO DOS DADOS

Carregar, explorar e entender o que temos

Nunca modele sem antes explorar os dados. Esta fase — chamada de EDA (Exploratory Data Analysis) — revela problemas, padrões e oportunidades.

2.1 — Carregando os Dados

```
# — CARREGAR DATASET —————
# Substitua o caminho pelo arquivo do seu projeto
df = pd.read_csv('nome_do_seu_arquivo.csv')

# Para rodar no Google Colab (fazer upload manual):
from google.colab import files
uploaded = files.upload()          # abre janela para selecionar arquivo
df = pd.read_csv('nome_do_arquivo.csv')

# Para carregar de URL pública:
# df = pd.read_csv('https://url-do-arquivo.csv')

# — VERIFICAÇÃO RÁPIDA —————
# número de linhas e colunas
print(df.shape)

# nomes das colunas disponíveis
print(df.columns.tolist())

# primeiras 5 linhas — ver como os dados se parecem
df.head()
```

2.2 — Raio-X Completo do Dataset

```
# — df.info() —————
# mostra: tipo de dado por coluna, contagem de não-nulos
# FUNDAMENTAL para detectar colunas com valores ausentes
df.info()

# — df.describe() —————
# estatísticas descritivas de todas as colunas numéricas
# min, max, média, desvio padrão, quartis
# .T transpõe a tabela (facilita a leitura)
df.describe().T.round(2)

# — VALORES ÚNICOS POR COLUNA —————
# quantos valores distintos há em cada coluna
df.nunique()

# contagem de ocorrências de cada categoria
df['coluna_categorica'].value_counts()

# proporção (em vez de contagem)
df['coluna_categorica'].value_counts(normalize=True).round(3)
```

2.3 — Análise de Valores Ausentes (Nulos)

```
# — IDENTIFICAR NULOS —————
# soma de nulos por coluna
nulos = df.isnull().sum()
print(nulos)

# percentual de nulos por coluna
pct_nulos = (df.isnull().sum() / len(df) * 100).round(1)
print(pct_nulos[pct_nulos > 0]) # só mostra colunas COM nulos

# — HEATMAP VISUAL DE NULOS —————
# visualmente mostra onde os nulos estão concentrados
import seaborn as sns
plt.figure(figsize=(10, 4))
sns.heatmap(df.isnull(), cbar=False, cmap='viridis', yticklabels=False)
plt.title('Mapa de Valores Ausentes')
plt.tight_layout()
plt.show()
```

2.4 — Visualização Exploratória Inicial

```
# — DISTRIBUIÇÃO DE UMA VARIÁVEL NUMÉRICA —————
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# histograma: mostra a distribuição de frequência
axes[0].hist(df['coluna_numerica'], bins=30, color='#2E75B6',
             edgecolor='white', alpha=0.85)
axes[0].axvline(df['coluna_numerica'].mean(), color='red',
               linestyle='--', linewidth=2, label='Média')
axes[0].axvline(df['coluna_numerica'].median(), color='green',
               linestyle=':', linewidth=2, label='Mediana')
axes[0].set_title('Distribuição')
axes[0].set_xlabel('Valor')
axes[0].set_ylabel('Frequência')
axes[0].legend()

# scatter: relação entre duas variáveis numéricas
axes[1].scatter(df['variavel_x'], df['variavel_y'],
               alpha=0.5, color='#1B3A6B', s=40, edgecolor='white')
axes[1].set_title('Variável X vs Variável Y')
axes[1].set_xlabel('Variável X')
axes[1].set_ylabel('Variável Y')

plt.tight_layout()
plt.show()
```

2.5 — Insights Iniciais com groupby

O `groupby` é um dos comandos mais poderosos do Pandas para EDA. Ele agrupa os dados por uma ou mais colunas e aplica uma função de agregação — revelando padrões que as estatísticas globais escondem.

Por que usar groupby na EDA?

A média global pode mascarar diferenças importantes entre grupos.

Exemplo: o preço médio geral é R\$ 800 mil, mas apartamentos custam R\$ 500 mil e coberturas R\$ 2,5 milhões — o `groupby` revela isso.
Use antes de modelar para entender quais categorias mais influenciam o target.

2.5.1 — Agregações Simples por Grupo

```
# — MÉDIA POR CATEGORIA —————
# qual grupo tem o maior valor médio?
df.groupby('coluna_categorica')['coluna_numerica'].mean()
.sort_values(ascending=False)

# — MEDIANA POR CATEGORIA —————
# mais robusta que a média quando há outliers
df.groupby('coluna_categorica')['coluna_numerica'].median()
.sort_values(ascending=False)

# — CONTAGEM POR CATEGORIA —————
# quantos registros há em cada grupo?
df.groupby('coluna_categorica').size().sort_values(ascending=False)

# — VALOR MÁXIMO E MÍNIMO POR GRUPO —————
df.groupby('coluna_categorica')['coluna_numerica'].max()
df.groupby('coluna_categorica')['coluna_numerica'].min()
```

2.5.2 — Múltiplas Funções de Uma Vez com `agg()`

```
# — agg() — VÁRIAS ESTATÍSTICAS SIMULTANEAMENTE —————
# retorna uma tabela com várias métricas por grupo
df.groupby('coluna_categorica')['coluna_numerica'].agg(
    contagem = 'count', # quantos registros
    media    = 'mean',  # média
    mediana  = 'median', # mediana
    minimo   = 'min',   # menor valor
    maximo    = 'max',  # maior valor
    desvio   = 'std',   # desvio padrão
).round(2)

# — FUNÇÕES DIFERENTES POR COLUNA —————
# útil para resumir várias variáveis ao mesmo tempo
df.groupby('coluna_categorica').agg({
    'coluna_numerica1': 'mean',
    'coluna_numerica2': 'median',
    'coluna_numerica3': 'count'
}).round(2)
```

2.5.3 — Agrupamento por Dois Critérios

```
# — AGRUPAR POR DUAS COLUNAS —————
# revela interações entre categorias
df.groupby(['categ1', 'categ2'])['coluna_numerica']
.mean().round(2).sort_values(ascending=False)

# — CONTAR COMBINAÇÕES —————
# quantos registros existem para cada combinação?
df.groupby(['categ1', 'categ2']).size()
```

```
.sort_values(ascending=False)

# — PIVOT TABLE — visão em grade (como Excel) —
# linhas = categ1, colunas = categ2, valores = média
df.pivot_table(values='coluna_numerica',
                index='categ1',
                columns='categ2',
                aggfunc='mean').round(2)
```

2.5.4 — Identificar Grupos com Comportamento Atípico

```
# — DETECTAR GRUPOS COM MAIOR DESVIO DA MÉDIA GERAL —
media_global = df['coluna_numerica'].mean()

medias_grupo = df.groupby('coluna_categorica')['coluna_numerica'].mean()

# diferença percentual de cada grupo em relação à média geral
desvio_pct = ((medias_grupo - media_global) / media_global * 100).round(1)
print(desvio_pct.sort_values(ascending=False))

# — TOP 5 E BOTTOM 5 —
# grupos com os maiores valores
print('--- Top 5 ---')
print(medias_grupo.sort_values(ascending=False).head(5))

# grupos com os menores valores
print('--- Bottom 5 ---')
print(medias_grupo.sort_values(ascending=True).head(5))
```

✓ Boas práticas com groupby na EDA

Sempre combine groupby com sort_values() para destacar os grupos mais relevantes. Use .reset_index() após o groupby para transformar o resultado em DataFrame manipulável. Compare a mediana (robusta) com a média (sensível) — diferenças grandes indicam outliers no grupo. Anote os insights encontrados — eles guiarão as decisões de feature engineering na Fase 3.

⚠ Checklist da Fase 2

- ☐ df.info() executado — tipos de dados verificados
- ☐ df.describe() analisado — outliers suspeitos identificados
- ☐ Nulos contados por coluna (isnull().sum())
- ☐ Distribuição das principais variáveis visualizada
- ☐ groupby executado — padrões por categoria identificados
- ☐ Perguntas iniciais respondidas: quantos registros? quais colunas?

3

PREPARAÇÃO DOS DADOS

Limpar, transformar e criar features

Esta fase consome 60–80% do tempo de um projeto real. Dados sujos produzem modelos ruins — "garbage in, garbage out". Aqui tratamos nulos, outliers, encoding e criamos novas variáveis.

3.1 — Criar uma Cópia de Segurança

```
# SEMPRE trabalhe em uma cópia, nunca modifique o original
# df_raw = dados originais intocados
# df_limpo = cópia para trabalhar
df_limpo = df.copy()

# Para verificar: ambos começam iguais
print(f"Original: {df.shape} | Cópia: {df_limpo.shape}")
```

3.2 — Verificar a Proporção de Valores das Colunas Categóricas

Para colunas do tipo texto (object), é essencial conhecer a distribuição de cada categoria — quais valores existem e em que proporção. O laço abaixo percorre todas as colunas e exibe automaticamente apenas as categóricas.

```
# — PROPORÇÃO DE VALORES POR COLUNA —————
# percorre todas as colunas do DataFrame
for col in df.columns:

    # se a coluna for do tipo texto (object) → categórica
    if df.dtypes[col] == 'object':
        print('===', col, '===')

        # exibe a proporção de cada categoria em %
        # dropna=False → inclui NaN na contagem
        print(df[col].value_counts(normalize=True, dropna=False).mul(100).round(2))

    # senão → coluna numérica: exibe % preenchido e % faltante
    else:
        print('===', col, '===')

        total = len(df)
        nulos = df[col].isna().sum() # quantidade de nulos
        preenchidos = total - nulos # quantidade preenchida
        porc_preenchidos = round((preenchidos / total) * 100, 2) # % preenchido
        porc_faltantes = round(nulos / total * 100, 2) # % faltante

        print(f'Quantidade de preenchidos: {preenchidos} / Porcentagem de preenchidos: {porc_preenchidos:.2f}%')
        print(f'Quantidade de faltantes: {nulos} / Porcentagem de faltantes: {porc_faltantes:.2f}%')

    # linha separadora entre colunas
    print('=' * 30)
```

i Como interpretar o resultado

`value_counts(normalize=True)` retorna a proporção de cada valor entre 0 e 1.

Multiplicando por 100, obtemos o percentual — ex: 0.45 → 45%.

Use para detectar categorias dominantes, categorias raras ou erros de digitação.

3.2.1 — Corrigindo Valores Inconsistentes em Colunas Categóricas

Ao inspecionar as colunas com `value_counts()`, é comum encontrar variações indesejadas de um mesmo valor — como "Nao", "não", "n", "N". O laço abaixo percorre cada valor da coluna e, se for diferente do valor correto, aplica o `replace()` para substituí-lo.

★ Técnica recomendada — Inspeção + Substituição controlada

Defina o `valor_desejado` como a forma canônica correta.

O laço `for` inspeciona cada linha individualmente.

O `replace()` só é chamado quando o valor é diferente do correto.

Resultado: controle total sobre o que é substituído, sem efeitos colaterais.

```
# — CORRIGIR VALORES INCONSISTENTES —————
# define o valor correto (forma canônica)
valor_desejado = 'nao'

# percorre cada linha da coluna pelo índice e valor
for i, valor in df['col'].items():

    # se o valor for diferente do correto → substituir
    if valor != valor_desejado:
        df['col'] = df['col'].replace(valor, valor_desejado)

# — VERIFICAR O RESULTADO —————
# deve exibir apenas o valor_desejado
print(df['col'].value_counts(dropna=False))
```

✓ Quando usar esta técnica

Após rodar o `value_counts()` no tópico 3.2 e identificar variações indesejadas.

Repita o bloco para cada coluna categórica que apresentar inconsistências.

Execute o `value_counts()` novamente após a correção para confirmar o resultado.

⚠ Atenção — este código NÃO trata valores faltantes (NaN)

No Python, NaN nunca é igual a nada — nem a si mesmo — portanto a condição `if valor != valor_desejado` não o captura de forma confiável.

Valores NaN permanecem intactos após este laço.

Para tratar valores faltantes, utilize `fillna()` conforme o tópico 3.3.

3.2.2 — Identificar e Corrigir Nulos Mascarados

Datasets reais frequentemente representam "ausência de valor" de formas não padronizadas — como ?, -, --, N/D ou espaço em branco. O Pandas não os reconhece como nulos automaticamente, o que faz

com que passem despercebidos no `isnull()`. O tutorial abaixo garante controle total: inspecionar primeiro, decidir, substituir e confirmar.

★ Tutorial — 4 passos para eliminar nulos mascarados

Passo 1 → Inspecionar todas as colunas com `value_counts(dropna=False)`.

Passo 2 → Identificar visualmente os valores suspeitos em cada coluna.

Passo 3 → Substituir os identificados por `np.nan` coluna a coluna.

Passo 4 → Confirmar localmente (por coluna) e globalmente (`isnull().sum()`).

```
# — PASSO 1: INSPECIONAR TODAS AS COLUNAS —————
# rode esta célula e analise a saída com atenção
# procure por valores como: ?, -, --, N/D, none, espaço etc.

for col in df.columns:
    print('===', col, '===')
    print(df[col].value_counts(dropna=False))
    print('=' * 30)

# — PASSO 2: IDENTIFICAR —————
# após analisar a saída do Passo 1, anote quais valores
# são nulos mascarados em cada coluna do seu dataset

# — PASSO 3: SUBSTITUIR POR NaN —————
# importe numpy para usar np.nan (nulo oficial do Pandas)
import numpy as np

# substitua "col" pela coluna real e o valor pelo encontrado no Passo 1
df['col'] = df['col'].replace('?', np.nan) # valor desconhecido
df['col'] = df['col'].replace('-', np.nan) # campo vazio com traço
df['col'] = df['col'].replace('--', np.nan) # variação de traço duplo
df['col'] = df['col'].replace('N/D', np.nan) # não disponível
df['col'] = df['col'].replace(' ', np.nan) # espaço em branco
# repita para cada coluna e valor identificado no Passo 1

# — PASSO 4A: CONFIRMAR POR COLUNA —————
# o NaN deve aparecer na contagem — se não aparecer, revisar o Passo 3
print(df['col'].value_counts(dropna=False))

# — PASSO 4B: CONFIRMAR GLOBALMENTE —————
# agora o isnull() captura todos os nulos, inclusive os mascarados
# use este resultado para guiar o tratamento no tópico 3.3
print(df.isnull().sum())
```

Por que `np.nan` e não `None` ou `string vazia`?

`np.nan` é o padrão reconhecido pelo Pandas em todas as operações: `isnull()`, `fillna()`, `dropna()` e `describe()`.

`None` funciona em colunas object mas pode causar erros em colunas numéricas.

String vazia ("") não é reconhecida como nulo — permaneceria invisível para `isnull()`.

3.3 — Tratamento de Valores Nulos

```

# — REMOVER LINHAS COM NULOS (use com cautela) —————
# recomendado apenas quando a quantidade de nulos é pequena
df_limpo = df_limpo.dropna()

# — PREENCHER COM MEDIANA (recomendado para numéricos) ———
# a mediana é mais robusta que a média em presença de outliers
df_limpo['coluna_numerica'] = df_limpo['coluna_numerica'].fillna(
    df_limpo['coluna_numerica'].median()
)

# — PREENCHER COM MÉDIA —————
df_limpo['coluna_numerica'] = df_limpo['coluna_numerica'].fillna(
    df_limpo['coluna_numerica'].mean()
)

# — PREENCHER COM MODA (para colunas categóricas) —————
# moda = valor mais frequente
df_limpo['coluna_categorica'] = df_limpo['coluna_categorica'].fillna(
    df_limpo['coluna_categorica'].mode()[0]
)

# — CONFIRMAR QUE NÃO HÁ MAIS NULOS —————
print(df_limpo.isnull().sum())

```

3.4 — Detecção e Tratamento de Outliers

```

# — MÉTODO 1: IQR (Intervalo Interquartil) —————
# método estatístico padrão para detectar outliers
Q1 = df_limpo['coluna_numerica'].quantile(0.25)
Q3 = df_limpo['coluna_numerica'].quantile(0.75)
IQR = Q3 - Q1

# limites: valores fora destes são considerados outliers
lim_inf = Q1 - 1.5 * IQR      # limite inferior
lim_sup = Q3 + 1.5 * IQR      # limite superior

n_out = ((df_limpo['coluna_numerica'] < lim_inf) |
         (df_limpo['coluna_numerica'] > lim_sup)).sum()
print(f"Outliers detectados: {n_out}")

# — MÉTODO 2: CORTE POR REGRA DE NEGÓCIO —————
# mais simples e intuitivo quando você conhece o domínio
LIMITE_MAXIMO = 5000          # defina com base no contexto
df_limpo = df_limpo[df_limpo['coluna_numerica'] <= LIMITE_MAXIMO]

# — REMOVER OUTLIERS COM IQR —————
mask = (df_limpo['coluna_numerica'] >= lim_inf) & (df_limpo['coluna_numerica'] <=
lim_sup)
df_sem_outliers = df_limpo[mask].copy()
print(f"Registros antes: {len(df_limpo)} | depois: {len(df_sem_outliers)}")

```

3.5 — Encoding de Variáveis Categóricas

```

# — POR QUE FAZER ENCODING? —————
# modelos de ML só aceitam números, não texto
# encoding = converter texto em número

```

```
# — ONE-HOT ENCODING (recomendado para maioria dos casos)
# cria uma coluna binária (0 ou 1) para cada categoria
# use quando as categorias NÃO têm ordem (ex: tipo de imóvel)
df_encoded = pd.get_dummies(df_limpo, columns=['coluna_categorica'],
                             drop_first=True) # evitar multicolinearidade

# — LABEL ENCODING (use apenas para árvores de decisão) —
# substitui cada categoria por um número inteiro
from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
df_limpo['coluna_encoded'] = le.fit_transform(df_limpo['coluna_categorica'])

# verificar o mapeamento criado
print(dict(zip(le.classes_, le.transform(le.classes_))))
```

3.6 — Engenharia de Features (Feature Engineering)

```
# — CRIAR NOVAS VARIÁVEIS —————
# novas features podem capturar relações que as originais não capturam

# Exemplo 1: calcular idade a partir do ano de construção
df_limpo['idade'] = 2025 - df_limpo['ano_construcao'].astype(int)

# Exemplo 2: criar razão entre duas variáveis
df_limpo['preco_por_m2'] = df_limpo['preco_mil'] / df_limpo['area_m2']

# Exemplo 3: criar variável binária (flag)
df_limpo['e_novo'] = (df_limpo['idade'] <= 5).astype(int)

# verificar as novas colunas
print(df_limpo[['idade', 'preco_por_m2', 'e_novo']].head())
```

3.7 — Análise de Correlação de Pearson



O que é a Correlação de Pearson?

É uma medida estatística que indica a força e a direção da relação linear entre duas variáveis numéricas. O resultado é o coeficiente r , que varia de -1 a +1.

$r = +1$ → relação positiva perfeita: quando X sobe, Y sobe na mesma proporção.

$r = -1$ → relação negativa perfeita: quando X sobe, Y desce na mesma proporção.

$r = 0$ → sem relação linear entre as variáveis.

Em Machine Learning, usamos r para selecionar quais variáveis têm mais relação com o target — quanto maior o $|r|$, mais útil a feature tende a ser para o modelo.



O que é um Heatmap de Correlação?

É uma representação visual da matriz de correlação — uma tabela onde cada célula mostra o valor r entre dois pares de variáveis, colorida por intensidade.

Cores quentes (vermelho) → correlação positiva forte (próximo de +1).

Cores frias (azul) → correlação negativa forte (próximo de -1).

Cores neutras (branco/bege) → sem correlação linear (próximo de 0).

A diagonal principal sempre vale 1,00 — toda variável tem correlação perfeita consigo mesma.

```
# — MATRIZ DE CORRELAÇÃO —————
```

```

# r = 1: correlação positiva perfeita (X sobe, Y sobe)
# r = -1: correlação negativa perfeita (X sobe, Y desce)
# r = 0: sem correlação linear

# calcular correlação de todas as variáveis numéricas
correlacao = df_limpo.select_dtypes(include="number").corr()

# ver correlação especificamente com o target
corr_target =
correlacao['coluna_alvo'].drop('coluna_alvo').abs().sort_values(ascending=False)
print(corr_target)

# — HEATMAP DE CORRELAÇÃO —
# visualização mais clara da matriz
numericas = df_limpo.select_dtypes(include='number')
plt.figure(figsize=(10, 7))
sns.heatmap(numericas.corr(), annot=True, fmt='.2f',
            cmap='coolwarm', center=0,
            linewidths=0.5, annot_kws={'size': 9})
plt.title('Matriz de Correlação de Pearson', fontsize=13)
plt.tight_layout()
plt.show()

```

Valor de r	Interpretação	O que fazer
0,90 a 1,00	Correlação muito forte (positiva)	Excelente feature para o modelo
0,70 a 0,89	Correlação forte (positiva)	Boa feature — incluir no modelo
0,50 a 0,69	Correlação moderada	Feature razoável — avaliar inclusão
0,30 a 0,49	Correlação fraca	Pouco impacto — incluir com cautela
0,00 a 0,29	Correlação muito fraca	Provavelmente não ajuda o modelo
Valores negativos	Mesma lógica, mas relação inversa	Correlação de -0,85 é tão forte quanto +0,85

⚠ Checklist da Fase 3

- ☐ Cópia criada (df_limpo = df.copy())
- ☐ Nulos tratados em todas as colunas
- ☐ Outliers identificados e tratados
- ☐ Variáveis categóricas convertidas para números
- ☐ Novas features criadas (se relevante)
- ☐ Correlação com o target calculada

4

VISUALIZAÇÃO DE DADOS

Gráficos sns e plt para análise exploratória

Antes de modelar, visualizar os dados é essencial para entender distribuições, relações e padrões. Os gráficos abaixo são os mais utilizados nas aulas e exercícios — todos aplicáveis diretamente ao seu dataset.

Tabela de Referência — Tipos de Gráfico

Gráfico	Biblioteca	Quando usar	Finalidade	Sintaxe básica
hist / histplot	plt / sns	Distribuição de uma variável numérica	Ver concentração, assimetria e outliers	plt.hist(df['col'], bins=30)
scatter / scatterplot	plt / sns	Relação entre duas variáveis numéricas	Verificar correlação visual e presença de outliers	plt.scatter(df['x'], df['y'])
boxplot	sns	Comparar distribuição entre grupos	Ver mediana, quartis e outliers por categoria	sns.boxplot(data=df, x='cat', y='num')
violinplot	sns	Distribuição completa por grupo	Combina boxplot com curva de densidade	sns.violinplot(data=df, x='cat', y='num')
barplot	sns	Comparar médias entre categorias	Média com intervalo de confiança por grupo	sns.barplot(data=df, x='cat', y='num')
heatmap	sns	Correlação entre variáveis numéricas	Identificar quais features se relacionam com o target	sns.heatmap(df.corr(), annot=True)
lmplot	sns	Regressão visual por grupo	Ver linha de tendência e dispersão por categoria	sns.lmplot(data=df, x='x', y='y', hue='cat')

Histograma — plt.hist / sns.histplot

Mostra como os valores de uma variável numérica se distribuem. A linha vermelha indica a média e a verde a mediana — quando diferem muito, há assimetria ou outliers.

```
# — HISTOGRAMA COM MATPLOTLIB —————
fig, ax = plt.subplots(figsize=(10, 5))

ax.hist(df['coluna_numerica'], bins=30,
        color='#2E75B6', edgecolor='white', alpha=0.85)

# linha da média
ax.axvline(df['coluna_numerica'].mean(),
           color='red', linestyle='--', linewidth=2, label='Média')
# linha da mediana
ax.axvline(df['coluna_numerica'].median(),
           color='green', linestyle=':', linewidth=2, label='Mediana')

ax.set_title('Distribuição de coluna_numerica')
ax.set_xlabel('Valor')
ax.set_ylabel('Frequência')
```

```

ax.legend()
plt.tight_layout()
plt.show()

# — HISTPLOT COM SEABORN (com KDE e hue) —————
# kde=True → curva de densidade suavizada
# hue → separa por categoria com cores diferentes
sns.histplot(data=df, x='coluna_numerica',
              hue='coluna_categorica',
              kde=True, element='step')
plt.title('Distribuição por Categoria')
plt.show()

```

Scatter — plt.scatter / sns.scatterplot

Plota um ponto por registro relacionando duas variáveis numéricas. Ideal para verificar correlação visual — pontos em diagonal indicam relação, pontos dispersos indicam ausência de relação.

```

# — SCATTER COM MATPLOTLIB —————
fig, ax = plt.subplots(figsize=(10, 6))

ax.scatter(df['variavel_x'], df['variavel_y'],
           alpha=0.5, color='#1B3A6B',
           s=40, edgecolors='white')

ax.set_title('Variável X vs Variável Y')
ax.set_xlabel('Variável X')
ax.set_ylabel('Variável Y')
plt.tight_layout()
plt.show()

# — SCATTERPLOT COM SEABORN (com hue por categoria) —————
# hue → colore os pontos por categoria
sns.scatterplot(data=df, x='variavel_x', y='variavel_y',
                hue='coluna_categorica',
                alpha=0.6, s=60)
plt.title('X vs Y por Categoria')
plt.show()

```

Boxplot — sns.boxplot

Resume a distribuição de uma variável numérica por grupo. A caixa vai do Q1 ao Q3 (50% dos dados), a linha central é a mediana e os pontos fora dos bigodes são outliers.

```

# — BOXPLOT COM SEABORN —————
fig, ax = plt.subplots(figsize=(10, 6))

sns.boxplot(data=df, x='coluna_categorica', y='coluna_numerica',
            order=['Cat_A', 'Cat_B', 'Cat_C'], # ordem das categorias
            palette='Set2', ax=ax)

ax.set_title('Distribuição por Grupo')
ax.set_xlabel('Categoria')
ax.set_ylabel('Valor')
plt.tight_layout()
plt.show()

```


Violinplot — sns.violinplot

Versão aprimorada do boxplot — além de mostrar Q1, mediana e Q3, exibe a curva de densidade completa. A largura do "violino" indica onde os dados são mais concentrados.

```
# — VIOLINPLOT COM SEABORN —————
fig, ax = plt.subplots(figsize=(10, 6))

sns.violinplot(data=df, x='coluna_categorica', y='coluna_numerica',
               inner='box',          # inner: box, quartile, point, stick
               palette='Set2', ax=ax)

ax.set_title('Distribuição Completa por Grupo')
ax.set_xlabel('Categoria')
ax.set_ylabel('Valor')
plt.tight_layout()
plt.show()
```

Barplot — sns.barplot

Compara a média de uma variável numérica entre categorias. As barras de erro mostram o intervalo de confiança de 95% — útil para avaliar se as diferenças entre grupos são estatisticamente relevantes.

```
# — BARPLOT COM SEABORN —————
fig, ax = plt.subplots(figsize=(10, 6))

sns.barplot(data=df, x='coluna_categorica', y='coluna_numerica',
            estimator='mean',      # função de agregação: mean, median, sum
            errorbar='ci',         # barra de erro: intervalo de confiança 95%
            palette='Blues_d', ax=ax)

ax.set_title('Média por Categoria')
ax.set_xlabel('Categoria')
ax.set_ylabel('Média')
plt.xticks(rotation=45) # rotaciona rótulos se forem longos
plt.tight_layout()
plt.show()
```

Heatmap de Correlação — sns.heatmap

Visualiza a matriz de correlação de Pearson. Cada célula mostra o valor r entre dois pares de variáveis, colorida por intensidade. Indispensável antes de selecionar features para o modelo.

```
# — HEATMAP DE CORRELAÇÃO —————
# selecionar apenas colunas numéricas
numericas = df.select_dtypes(include='number')

plt.figure(figsize=(10, 7))
sns.heatmap(numericas.corr(),
            annot=True,          # exibe o valor r em cada célula
            fmt='.2f',           # formato: 2 casas decimais
            cmap='coolwarm',     # paleta: azul (negativo) → vermelho (positivo)
            center=0,            # centraliza a escala no zero
            linewidths=0.5,      # linhas separadoras entre células
            annot_kws={'size': 9})

plt.title('Matriz de Correlação de Pearson', fontsize=13)
plt.tight_layout()
```

```
plt.show()
```

Lmplot — sns.lmplot

Combina scatter com linha de regressão linear. O parâmetro `hue` permite traçar uma reta por categoria — revelando se a relação entre X e Y muda conforme o grupo.

```
# — LMPLLOT COM SEABORN —
# lmplot opera diretamente no DataFrame — não usa fig/ax
g = sns.lmplot(data=df, x='variavel_x', y='variavel_y',
              hue='coluna_categorica', # reta por categoria
              height=5, aspect=2,
              scatter_kws={'alpha': 0.35, 's': 35},
              line_kws={'linewidth': 2.5},
              ci=95) # intervalo de confiança da reta

g.figure.suptitle('Regressão Visual: X vs Y por Categoria', y=1.02)
g.set_axis_labels('Variável X', 'Variável Y')
plt.tight_layout()
plt.show()
```

Subplots — Múltiplos Gráficos em uma Figura

Use `plt.subplots()` para combinar vários gráficos em uma única figura — muito útil para comparar distribuições lado a lado sem abrir várias janelas.

```
# — MÚLTIPLOS GRÁFICOS LADO A LADO —
# cria 1 linha e 2 colunas de gráficos
fig, axes = plt.subplots(1, 2, figsize=(14, 5))
fig.suptitle('Análise Exploratória', fontsize=13, fontweight='bold')

# gráfico da esquerda: histograma
axes[0].hist(df['coluna_numerica'], bins=30,
            color='#2E75B6', edgecolor='white')
axes[0].set_title('Distribuição')
axes[0].set_xlabel('Valor')
axes[0].set_ylabel('Frequência')

# gráfico da direita: scatter
axes[1].scatter(df['variavel_x'], df['variavel_y'],
               alpha=0.5, color='#C2185B', s=40)
axes[1].set_title('X vs Y')
axes[1].set_xlabel('Variável X')
axes[1].set_ylabel('Variável Y')

plt.tight_layout()
plt.show()
```

✓ Boas práticas de visualização

Sempre defina título (`set_title`), rótulos dos eixos (`set_xlabel`, `set_ylabel`) e legenda (`legend()`) — gráficos sem identificação não comunicam.

Use `alpha` entre 0.4 e 0.7 em scatter e histogramas para visualizar sobreposição de pontos.

`plt.tight_layout()` evita que os gráficos se sobreponham quando usar subplots.

`sns.set_theme(style="whitegrid")` melhora a legibilidade — execute uma vez no início do notebook.

5

MODELAGEM

Dividir dados, treinar e ajustar o modelo

5.1 — Separar Features (X) e Target (y)

```
# — DEFINIR FEATURES E TARGET —————
# X = variáveis de entrada (o que o modelo usa para prever)
# y = variável-alvo (o que queremos prever)

# features numéricas que serão usadas no modelo
FEATURES = ['coluna1', 'coluna2', 'coluna3']
TARGET = 'coluna_alvo'

# criar X e y
X = df_limpo[FEATURES]
y = df_limpo[TARGET]

print(f"X shape: {X.shape} → {X.shape[0]} exemplos, {X.shape[1]} features")
print(f"y shape: {y.shape} → {y.shape[0]} valores-alvo")
```

5.2 — Divisão Treino e Teste

Dividir os dados é obrigatório. O modelo aprende nos dados de treino e é avaliado nos dados de teste — que ele nunca viu. Avaliar no treino seria como "colar na prova".

```
# — train_test_split —————
from sklearn.model_selection import train_test_split

X_treino, X_teste, y_treino, y_teste = train_test_split(
    X,          # features
    y,          # target
    test_size=0.2, # 20% para teste, 80% para treino
    random_state=42 # semente: garante reprodutibilidade
)

# verificar os tamanhos
print(f'Treino: {X_treino.shape[0]} exemplos ({X_treino.shape[0]/len(X)*100:.0f}%)')
print(f'Teste: {X_teste.shape[0]} exemplos ({X_teste.shape[0]/len(X)*100:.0f}%)')
```

i Por que random_state=42?

A divisão treino/teste é aleatória. random_state garante que, ao rodar de novo, os mesmos dados vão para treino e os mesmos para teste.

Você pode usar qualquer número inteiro — 42 é uma convenção popular na comunidade de dados.

5.3 — Treinar o Modelo de Regressão Linear

```
# — REGRESSÃO LINEAR SIMPLES (1 feature) —————
from sklearn.linear_model import LinearRegression
```

```
# criar o objeto do modelo
modelo = LinearRegression()

# .fit() = fase de aprendizado (treino)
# o modelo ajusta internamente os coeficientes
modelo.fit(X_treino, y_treino)

# — GERAR PREVISÕES —
# previsões no treino (para comparar com teste)
y_pred_treino = modelo.predict(X_treino)

# previsões no teste (avaliação real do modelo)
y_pred_teste = modelo.predict(X_teste)

# — VER A EQUAÇÃO APRENDIDA —
# coef_ = inclinação da reta (impacto por unidade da feature)
# intercept_ = ponto de partida (valor quando X = 0)
for feat, coef in zip(FEATURES, modelo.coef_):
    print(f" {feat}: coeficiente = {coef:.4f}")
print(f" Intercepto: {modelo.intercept_:.2f}")
```

⚠ Checklist da Fase 4

- ☐ Features e target separados (X e y)
- ☐ Dados divididos em treino e teste (80/20)
- ☐ random_state definido para reprodutibilidade
- ☐ Modelo treinado com .fit(X_treino, y_treino)
- ☐ Previsões geradas para treino E teste

6

AVALIAÇÃO

Medir o desempenho real com RMSE, MAE e R^2

6.1 — As Métricas de Avaliação

Sempre calcule as métricas nos dados de TREINO e de TESTE e compare os dois — isso é a chave para detectar overfitting.

Métrica	O que mede	Unidade	Quando usar
RMSE	Raiz do erro quadrático médio — penaliza erros grandes	Mesma do target	Quando erros grandes são inaceitáveis
MAE	Erro médio absoluto — trata todos os erros igual	Mesma do target	Quando há outliers que distorcem o RMSE
R^2	Proporção da variância explicada pelo modelo	0 a 1 (sem unidade)	Para comparar modelos entre si

6.2 — Calcular e Comparar Métricas

```
# — IMPORTAR FUNÇÕES DE MÉTRICAS —————
from sklearn.metrics import mean_squared_error, r2_score, mean_absolute_error
import numpy as np

# — CALCULAR NO TREINO —————
rmse_treino = np.sqrt(mean_squared_error(y_treino, y_pred_treino))
mae_treino = mean_absolute_error(y_treino, y_pred_treino)
r2_treino = r2_score(y_treino, y_pred_treino)

# — CALCULAR NO TESTE —————
rmse_teste = np.sqrt(mean_squared_error(y_teste, y_pred_teste))
mae_teste = mean_absolute_error(y_teste, y_pred_teste)
r2_teste = r2_score(y_teste, y_pred_teste)

# — TABELA COMPARATIVA —————
print("=" * 50)
print("COMPARAÇÃO: TREINO vs TESTE")
print("=" * 50)
print(f" RMSE   Treino: {rmse_treino:.2f} | Teste: {rmse_teste:.2f}")
print(f" MAE    Treino: {mae_treino:.2f} | Teste: {mae_teste:.2f}")
print(f" R²     Treino: {r2_treino:.4f} | Teste: {r2_teste:.4f}")

# — DIAGNÓSTICO —————
dif_rmse = (rmse_teste - rmse_treino) / rmse_treino * 100
if dif_rmse < 10:
    print("DIAGNÓSTICO: Bom ajuste — modelo generaliza bem")
elif dif_rmse < 20:
    print("DIAGNÓSTICO: Leve overfitting — aceitável")
else:
    print("DIAGNÓSTICO: OVERFITTING — modelo decorou o treino")
```

6.3 — Gráfico Real vs Previsto e Resíduos

```
# — GRÁFICO DIAGNÓSTICO COMPLETO —
fig, axes = plt.subplots(1, 2, figsize=(14, 6))

# Gráfico 1: Real vs Previsto
# pontos na diagonal = previsões perfeitas
axes[0].scatter(y_teste, y_pred_teste, alpha=0.6,
                color='#0066CC', edgecolor='white', s=50)

# linha de referência (previsão perfeita)
ref = [y_teste.min(), y_teste.max()]
axes[0].plot(ref, ref, 'r--', linewidth=2, label='Previsão Perfeita')
axes[0].set_xlabel('Valor Real')
axes[0].set_ylabel('Valor Previsto')
axes[0].set_title('Real vs Previsto - Dados de TESTE')
axes[0].legend()

# Gráfico 2: Resíduos (erros)
# resíduos = diferença entre real e previsto
# um bom modelo tem resíduos aleatórios, próximos de zero
residuos = y_teste - y_pred_teste
axes[1].scatter(y_pred_teste, residuos, alpha=0.5,
                color='#C2185B', edgecolor='white', s=50)
axes[1].axhline(0, color='black', linestyle='--', linewidth=1.5)
axes[1].set_xlabel('Valor Previsto')
axes[1].set_ylabel('Resíduo (Real - Previsto)')
axes[1].set_title('Análise de Resíduos')

plt.tight_layout()
plt.show()
```

6.4 — Diagnóstico de Overfitting

Situação	RMSE Treino	RMSE Teste	Diagnóstico	Ação
Ideal	Baixo	Baixo (similar)	Modelo OK	Seguir para deploy
Overfitting	Muito baixo	Alto (>20% maior)	Modelo decorou	Simplificar modelo, regularizar
Underfitting	Alto	Alto	Modelo fraco	Adicionar features, modelo mais complexo

⚠ Checklist da Fase 5

- ☐ RMSE calculado no treino e no teste
- ☐ MAE calculado no treino e no teste
- ☐ R^2 calculado no treino e no teste
- ☐ Gráfico Real vs Previsto gerado
- ☐ Gráfico de resíduos gerado
- ☐ Diagnóstico de overfitting feito (diferença treino/teste)

7

IMPLANTAÇÃO

Salvar o modelo e criar função de previsão

7.1 — Salvar o Modelo com Pickle

```
# — SALVAR O MODELO TREINADO —————
# pickle = serialização: converte o objeto Python em arquivo
import pickle

with open('modelo_final.pkl', 'wb') as arquivo:
    pickle.dump(modelo, arquivo)

print('Modelo salvo com sucesso: modelo_final.pkl')

# — CARREGAR O MODELO MAIS TARDE —————
with open('modelo_final.pkl', 'rb') as arquivo:
    modelo_carregado = pickle.load(arquivo)

# verificar: deve dar as mesmas previsões
previsao_teste = modelo_carregado.predict(X_teste)
print('Modelo carregado e funcionando!')
```

7.2 — Função de Previsão Reutilizável

```
# — FUNÇÃO GENÉRICA PARA PREVER —————
# adapte os parâmetros para o seu projeto
def prever(modelo, valores_dict):
    """
    Recebe um dicionário com as features e retorna a previsão.
    Exemplo: prever(modelo, {"area_m2": 100, "quartos": 3})
    """
    import pandas as pd
    entrada = pd.DataFrame([valores_dict])
    resultado = modelo.predict(entrada)[0]
    return resultado

# — USO —————
novo_exemplo = {
    "coluna1": 100,    # substitua pelos seus valores
    "coluna2": 3,
    "coluna3": 2,
}

resultado = prever(modelo, novo_exemplo)
print(f"Previsão: {resultado:.2f}")
```

⚠ Checklist da Fase 6

- ☐ Modelo salvo em arquivo .pkl
- ☐ Modelo carregado e testado novamente
- ☐ Função de previsão criada e documentada
- ☐ Documentação do projeto atualizada

PIPELINE COMPLETA — SCRIPT DO INÍCIO AO FIM

Abaixo está o script completo consolidado, do carregamento ao modelo treinado. Adapte os nomes de colunas conforme seu dataset.

```
# =====
# PIPELINE COMPLETA CRISP-DM — REGRESSÃO LINEAR
# Substitua os nomes genéricos pelos do seu projeto
# =====

# FASE 0 — SETUP
import pandas as pd, numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score, mean_absolute_error
import pickle
%matplotlib inline
plt.rcParams['figure.figsize'] = (12, 5)
sns.set_theme(style='whitegrid')

# FASE 2 — CARREGAR E EXPLORAR
df = pd.read_csv('seu_arquivo.csv')
print(f"Shape: {df.shape}")
print(df.isnull().sum())

# FASE 3 — PREPARAR DADOS
df_limpo = df.copy()
df_limpo['coluna_nulos1'] =
df_limpo['coluna_nulos1'].fillna(df_limpo['coluna_nulos1'].median())
df_limpo['coluna_nulos2'] =
df_limpo['coluna_nulos2'].fillna(df_limpo['coluna_nulos2'].median())
df_limpo = df_limpo[df_limpo['coluna_alvo'] <= LIMITE_MAX] # remover outliers
df_limpo['feature_nova'] = df_limpo['colA'] / df_limpo['colB'] # nova feature

# FASE 4 — MODELAGEM
FEATURES = ['feat1', 'feat2', 'feat3']
TARGET = 'coluna_alvo'
X = df_limpo[FEATURES]
y = df_limpo[TARGET]
X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2,
random_state=42)
modelo = LinearRegression()
modelo.fit(X_treino, y_treino)
y_pred_treino = modelo.predict(X_treino)
y_pred_teste = modelo.predict(X_teste)

# FASE 5 — AVALIAÇÃO
rmse_tr = np.sqrt(mean_squared_error(y_treino, y_pred_treino))
rmse_te = np.sqrt(mean_squared_error(y_teste, y_pred_teste))
r2_tr = r2_score(y_treino, y_pred_treino)
r2_te = r2_score(y_teste, y_pred_teste)
print(f"RMSE Treino: {rmse_tr:.2f} | Teste: {rmse_te:.2f}")
print(f"R² Treino: {r2_tr:.4f} | Teste: {r2_te:.4f}")

# FASE 6 — SALVAR
with open('modelo_final.pkl', 'wb') as f:
    pickle.dump(modelo, f)
print('Pipeline completa — modelo salvo!')
```


APÊNDICE A — COMANDOS PANDAS ESSENCIAIS

Referência rápida dos comandos Pandas mais utilizados em Ciência de Dados.

A.1 — Carregamento e Inspeção

Comando	O que faz	Exemplo
<code>pd.read_csv('arq.csv')</code>	Lê arquivo CSV como DataFrame	<code>df = pd.read_csv('dados.csv')</code>
<code>pd.read_excel('arq.xlsx')</code>	Lê planilha Excel	<code>df = pd.read_excel('plan.xlsx')</code>
<code>df.head(n)</code>	Mostra as primeiras n linhas (padrão: 5)	<code>df.head(10)</code>
<code>df.tail(n)</code>	Mostra as últimas n linhas	<code>df.tail(5)</code>
<code>df.shape</code>	Retorna (linhas, colunas)	<code>print(df.shape)</code>
<code>df.columns</code>	Lista os nomes das colunas	<code>print(df.columns.tolist())</code>
<code>df.dtypes</code>	Tipo de dado de cada coluna	<code>print(df.dtypes)</code>
<code>df.info()</code>	Resumo: tipos, nulos, memória	<code>df.info()</code>
<code>df.describe()</code>	Estatísticas descritivas (count, mean, std, min, max...)	<code>df.describe().T</code>
<code>df.nunique()</code>	Nº de valores únicos por coluna	<code>df.nunique()</code>

A.2 — Seleção e Filtragem

Comando	O que faz	Exemplo
<code>df['col']</code>	Seleciona uma coluna (retorna Series)	<code>df['preco_mil']</code>
<code>df[['c1','c2']]</code>	Seleciona múltiplas colunas (retorna DataFrame)	<code>df[['area_m2','preco_mil']]</code>
<code>df.loc[linha, col]</code>	Seleciona por rótulo (label)	<code>df.loc[0:5, ['tipo','preco']]</code>
<code>df.iloc[linha, col]</code>	Seleciona por posição inteira	<code>df.iloc[0:3, 0:4]</code>
<code>df[df['col'] > x]</code>	Filtra linhas por condição	<code>df[df['preco_mil'] > 500]</code>
<code>df[(c1) & (c2)]</code>	Filtra com múltiplas condições (E)	<code>df[(df['tipo']=='Casa') & (df['area']>100)]</code>
<code>df[(c1) (c2)]</code>	Filtra com múltiplas condições (OU)	<code>df[(df['tipo']=='Casa') (df['tipo']=='Apt')]</code>
<code>df.query('expr')</code>	Filtra com expressão textual	<code>df.query('preco_mil > 1000 and bairro=="Lago Sul"')</code>
<code>df['col'].isin(lista)</code>	Verifica se valor está na lista	<code>df[df['tipo'].isin(['Casa','Cobertura'])]</code>

A.3 — Manipulação e Transformação

Comando	O que faz	Exemplo
<code>df['col'].fillna(v)</code>	Preenche nulos com valor v	<code>df['vagas'].fillna(df['vagas'].median())</code>
<code>df.dropna()</code>	Remove linhas com qualquer nulo	<code>df.dropna(subset=['col_importante'])</code>
<code>df.drop('col', axis=1)</code>	Remove uma coluna	<code>df.drop('col_desnecessaria', axis=1)</code>
<code>df.rename(columns={old:new})</code>	Renomeia colunas	<code>df.rename(columns={'antigo':'novo'})</code>
<code>df.sort_values(col)</code>	Ordena pelo valor de uma coluna	<code>df.sort_values('preco_mil', ascending=False)</code>
<code>df.copy()</code>	Cria cópia independente	<code>df_limpo = df.copy()</code>
<code>df.reset_index(drop=True)</code>	Reinicia o índice	<code>df = df.reset_index(drop=True)</code>
<code>df['col'] = expressao</code>	Cria ou sobrescreve coluna	<code>df['preco_m2'] = df['preco_mil']/df['area_m2']</code>
<code>pd.get_dummies(df, columns=['c'])</code>	One-hot encoding de colunas categóricas	<code>pd.get_dummies(df, columns=['tipo'])</code>

A.4 — Agregação e Agrupamento

Comando	O que faz	Exemplo
<code>df.groupby('col').mean()</code>	Agrupa e calcula média	<code>df.groupby('bairro')['preco_mil'].mean()</code>
<code>df.groupby('col').median()</code>	Agrupa e calcula mediana	<code>df.groupby('tipo')['area_m2'].median()</code>
<code>df.groupby('col').agg({c:'func'})</code>	Agrupa com funções diferentes por coluna	<code>df.groupby('bairro').agg({'preco':'mean','area':'max'})</code>
<code>df['col'].value_counts()</code>	Conta ocorrências de cada valor único	<code>df['tipo'].value_counts()</code>
<code>df['col'].value_counts(normalize=True)</code>	Proporção de cada valor único	<code>df['bairro'].value_counts(normalize=True)</code>
<code>df.pivot_table(...)</code>	Tabela dinâmica (como no Excel)	<code>df.pivot_table(values='preco', index='bairro', aggfunc='mean')</code>

A.5 — Nulos e Tipos

Comando	O que faz	Exemplo
<code>df.isnull().sum()</code>	Conta nulos por coluna	<code>print(df.isnull().sum())</code>

<code>df.isna().sum()</code>	Igual ao <code>isnull()</code> (sinônimo)	<code>print(df.isna().sum())</code>
<code>df.notnull()</code>	True onde valor NÃO é nulo	<code>df[df['col'].notnull()]</code>
<code>df['col'].astype(tipo)</code>	Converte tipo da coluna	<code>df['ano'].astype(int)</code>
<code>df.select_dtypes(include='number')</code>	Seleciona apenas colunas numéricas	<code>num = df.select_dtypes(include='number')</code>
<code>df['col'].str.lower()</code>	Transforma texto para minúsculas	<code>df['nome'].str.lower()</code>
<code>df['col'].str.strip()</code>	Remove espaços extras	<code>df['bairro'].str.strip()</code>

APÊNDICE B — GRÁFICOS MATPLOTLIB (plt) E SEABORN (sns)

Referência dos gráficos mais usados em Ciência de Dados, com código genérico e quando utilizar cada um.

B.1 — Estrutura Base de um Gráfico

```
# — ANATOMIA BÁSICA (matplotlib) —————
# fig = a "folha" onde o gráfico é desenhado
# ax = os eixos onde os dados são plotados
fig, ax = plt.subplots(figsize=(10, 6))

# (seu código de gráfico aqui)

ax.set_title('Título do Gráfico', fontsize=14, fontweight='bold')
ax.set_xlabel('Nome do Eixo X', fontsize=12)
ax.set_ylabel('Nome do Eixo Y', fontsize=12)
ax.legend() # mostra a legenda
plt.tight_layout() # ajusta margens automaticamente
plt.show() # exibe o gráfico

# — MÚLTIPLOS GRÁFICOS (subplots) —————
# cria 1 linha e 2 colunas de gráficos lado a lado
fig, axes = plt.subplots(1, 2, figsize=(14, 6))
# axes[0] = gráfico da esquerda
# axes[1] = gráfico da direita
```

B.2 — Catálogo de Gráficos Matplotlib (plt)

HISTOGRAMA — Distribuição de uma variável numérica

```
# Use para: ver a distribuição de frequência de uma variável numérica
# Responde: os valores estão concentrados onde? há assimetria?
plt.hist(df['coluna_numerica'], bins=30,
         color='#2E75B6', edgecolor='white', alpha=0.85)
plt.axvline(df['coluna_numerica'].mean(),
            color='red', linestyle='--', linewidth=2, label='Média')
plt.axvline(df['coluna_numerica'].median(),
            color='green', linestyle=':', linewidth=2, label='Mediana')
plt.title('Distribuição de coluna_numerica')
plt.xlabel('Valor') # nome do eixo X
plt.ylabel('Frequência') # nome do eixo Y
plt.legend()
plt.show()
```

SCATTER (Dispersão) — Relação entre duas variáveis numéricas

```
# Use para: verificar correlação visual entre duas variáveis
# Responde: quando X aumenta, Y também aumenta?
plt.scatter(df['variavel_x'], df['variavel_y'],
            alpha=0.5, # transparência (0=invisível, 1=opaco)
```

```

        color='#1B3A6B',
        s=40,          # tamanho dos pontos
        edgecolors='white')
plt.title('Variável X vs Variável Y')
plt.xlabel('Variável X')
plt.ylabel('Variável Y')
plt.show()

```

BAR CHART (Barras) — Comparação de categorias

```

# Use para: comparar valores entre categorias
# Responde: qual categoria tem o maior/menor valor?
contagem = df['coluna_categorica'].value_counts()

plt.bar(contagem.index, contagem.values, color='#2E75B6', edgecolor='white')
plt.title('Contagem por Categoria')
plt.xlabel('Categoria')
plt.ylabel('Contagem')
plt.xticks(rotation=45) # rotaciona os rótulos do eixo X
plt.tight_layout()
plt.show()

```

B.3 — Catálogo de Gráficos Seaborn (sns)

O Seaborn é construído sobre o matplotlib e oferece gráficos estatísticos com visual mais elaborado e integração direta com DataFrames.

sns.histplot — Histograma com curva de densidade (KDE)

```

# Use para: ver distribuição + comparar por categoria (hue)
sns.histplot(data=df, x='coluna_numerica',
             hue='coluna_categorica', # separar por cor
             kde=True,                # curva de densidade suave
             element='step')          # estilo: step, bars, poly
plt.title('Distribuição por Categoria')
plt.show()

```

sns.boxplot — Resumo estatístico e outliers

```

# Use para: comparar distribuições entre grupos
# Mostra: Q1, mediana, Q3, e pontos fora = outliers
sns.boxplot(data=df, x='coluna_categorica', y='coluna_numerica',
            order=['Cat_A', 'Cat_B', 'Cat_C'], # ordem das categorias
            palette='Set2')                   # paleta de cores
plt.title('Distribuição de Valores por Grupo')
plt.show()

```

sns.scatterplot — Dispersão com categorias por cor

```

# Use para: scatter com separação visual por categoria
sns.scatterplot(data=df, x='variavel_x', y='variavel_y',
               hue='coluna_categorica', # cor por categoria

```



```

        alpha=0.6, s=60)
plt.title('Variável X vs Y por Categoria')
plt.show()

```

sns.heatmap — Mapa de calor (correlação / nulos)

```

# — Heatmap de Correlação —————
numericas = df.select_dtypes(include='number')
sns.heatmap(numericas.corr(), annot=True, fmt='.2f',
            cmap='coolwarm', # coolwarm, Blues, RdYlGn...
            center=0, # centraliza a escala de cor no 0
            linewidths=0.5, # linhas entre células
            annot_kws={'size': 9})
plt.title('Matriz de Correlação de Pearson')
plt.show()

# — Heatmap de Nulos —————
sns.heatmap(df.isnull(), cbar=False, cmap='viridis', yticklabels=False)
plt.title('Mapa de Valores Ausentes')
plt.show()

```

sns.lmplot — Regressão visual por grupo

```

# Use para: visualizar a linha de regressão por categoria
g = sns.lmplot(data=df, x='variavel_x', y='variavel_y',
              hue='coluna_categorica', # linha por categoria
              height=5, aspect=2,
              scatter_kws={'alpha': 0.35, 's': 35},
              line_kws={'linewidth': 2.5}, ci=95)
g.figure.suptitle('Regressão Visual por Grupo', y=1.02)
g.set_axis_labels('Eixo X', 'Eixo Y')
plt.tight_layout()
plt.show()

```

sns.violinplot — Distribuição completa por grupo

```

# Use para: combinar boxplot + distribuição de densidade
sns.violinplot(data=df, x='coluna_categorica', y='coluna_numerica',
              inner='box') # inner: box, quartile, point, stick
plt.title('Distribuição por Grupo (Violin)')
plt.show()

```

sns.barplot — Média com intervalo de confiança

```

# Use para: comparar médias entre grupos, com erro padrão
sns.barplot(data=df, x='coluna_categorica', y='coluna_numerica',
            estimator='mean', # pode ser median, sum...
            errorbar='ci', # mostra intervalo de confiança
            palette='Blues_d')
plt.title('Média por Categoria (com IC 95%)')
plt.show()

```

B.4 — Tabela Resumo: Qual Gráfico Usar?

Pergunta que você quer responder	Gráfico Recomendado	Biblioteca
Como os valores de uma variável se distribuem?	histplot, hist	sns, plt
Existem outliers em uma coluna?	boxplot, violinplot	sns
Qual a relação entre X e Y?	scatter, scatterplot, lmplot	plt, sns
Como as categorias se comparam?	barplot, bar	sns, plt
Qual a correlação entre todas as variáveis?	heatmap (corr)	sns
Onde estão os valores ausentes?	heatmap (isnull)	sns
Qual a distribuição X por categoria?	boxplot, violinplot, histplot com hue	sns
Como a regressão se comporta por grupo?	lmplot	sns

B.5 — Dicas de Personalização Visual

```
# — PALETAS DE CORES SEABORN —
# Qualitativas (para categorias): 'Set1','Set2','Set3','tab10','Paired'
# Sequenciais (para valores):      'Blues','Greens','Oranges','viridis'
# Divergentes (para correlação):  'coolwarm','RdBu','RdYlGn'

# — TEMAS SEABORN —
# whitegrid: fundo branco com grade cinza (mais comum)
# darkgrid:  fundo cinza com grade
# white:     fundo branco sem grade
# ticks:     apenas marcas nos eixos
sns.set_theme(style='whitegrid', palette='Set2')

# — FORMATAR EIXO Y COMO MOEDA (R$) —
import matplotlib.ticker as mticker
ax.yaxis.set_major_formatter(mticker.FuncFormatter(
    lambda x, _: f'R$ {x:,.0f}'))

# — ADICIONAR RÓTULOS NAS BARRAS —
for bar in ax.patches:
    ax.text(
        bar.get_x() + bar.get_width() / 2,
        bar.get_height() + 0.5,
        f'{bar.get_height():.1f}',
        ha="center", va="bottom", fontsize=9
    )
```

APÊNDICE C — ERROS COMUNS E SOLUÇÕES

Mensagem de Erro	Causa Provável	Solução
FileNotFoundError: nome.csv	Arquivo não está no caminho informado	Verifique o caminho. No Colab use files.upload()
KeyError: nome_coluna	Nome de coluna errado (maiúsculas, espaços)	Use df.columns para ver os nomes exatos
ValueError: could not convert string to float	Coluna tem texto onde se espera número	Use pd.to_numeric(df['col'], errors='coerce')
Cannot use mean with non-numeric data	Tentou calcular média em coluna de texto	Selecione apenas colunas numéricas: df.select_dtypes('number')
Input contains NaN	Há nulos nas features antes do train/test split	Execute tratamento de nulos antes de criar X e y
R ² negativo	Modelo pior que prever a média — overfitting severo ou bug	Verifique se está usando y_pred do teste com y_teste
RMSE muito alto (>50% da média)	Features erradas, nulos não tratados, outliers no target	Revisar tratamento de dados e seleção de features

GLOSSÁRIO TÉCNICO

Termo	Definição
DataFrame	Estrutura de dados tabular do Pandas — como uma planilha Excel programável
Series	Uma coluna de um DataFrame — lista unidimensional com índice
Feature / Variável independente	Coluna de entrada usada pelo modelo para aprender (ex: área_m2, quartos)
Target / Variável dependente	Coluna que o modelo deve prever (ex: preco_mil)
EDA	Exploratory Data Analysis — exploração visual e estatística dos dados
Encoding	Conversão de variável categórica (texto) em número para o modelo entender
One-hot Encoding	Cria colunas binárias (0 ou 1) para cada categoria — mais comum
Outlier	Valor atípico — muito diferente da maioria dos dados
IQR	Intervalo Interquartil (Q3 - Q1) — método para detectar outliers
train_test_split	Divisão automática em dados de treino (aprender) e teste (avaliar)
Overfitting	Modelo "decorou" o treino mas falha em dados novos (treino ótimo, teste ruim)
Underfitting	Modelo muito simples para capturar os padrões (treino ruim, teste ruim)
RMSE	Root Mean Squared Error — raiz do erro quadrático médio — mesma unidade do target
MAE	Mean Absolute Error — erro médio absoluto — robusto a outliers
R ²	Coefficiente de determinação — de 0 a 1 — quanto o modelo explica a variância
Correlação de Pearson	Mede a relação linear entre duas variáveis (de -1 a +1)
pickle	Biblioteca Python para serializar objetos — salvar modelos em arquivo
random_state	Semente aleatória — garante reprodutibilidade dos resultados
CRISP-DM	Metodologia padrão para projetos de Data Science em 6 fases iterativas